This ICCV workshop paper is the Open Access version, provided by the Computer Vision Foundation. Except for this watermark, it is identical to the accepted version; the final published version of the proceedings is available on IEEE Xplore.

SSIG：一种用于平面布局相似性度量的视觉引导图编辑距离

卡斯珀·C·J范·恩赫伦堡 塞兰·哈德米 扬·C范·赫梅尔特 代尔夫特理工大学

摘要

*We propose a simple yet effective metric that measures structural similarity between visual instances of architectural floor plans, without the need for learning. Qualitatively, our experiments show that the retrieval results are similar to deeply learned methods. Effectively comparing instances of floor plan data is paramount to the success of machine understanding of floor plan data, including the assessment of floor plan generative models and floor plan recommendation systems. Comparing visual floor plan images goes beyond a sole pixel-wise visual examination and is crucially about similarities and differences in the shapes and relations between subdivisions that compose the layout. Currently, deep metric learning approaches are used to learn a pair-wise vector representation space that closely mimics the structural similarity, in which the models are trained on similarity labels that are obtained by Intersection-over-Union (IoU). To compensate for the lack of structural awareness in IoU, graph-based approaches such as Graph Matching Networks (GMNs) are used, which require pairwise inference for comparing data instances, making GMNs less practical for retrieval applications. In this paper, an effective evaluation metric for judging the structural similarity of floor plans, coined **SSIG** (**S**tructural **S**imilarity by **I**oU and **GED**), is proposed based on both image and graph distances. In addition, an efficient algorithm is developed that uses SSIG to rank a large-scale floor plan database. Code will be openly available.*

1. 引言

平面图作为建筑设计中最为重要的表达与思维媒介之一，是特定建筑楼层的水平正投影。平面图是一种简洁而有力的空间表征方式，能够传达关于建筑构成结构的丰富信息——包括各功能分区的形态、比例及其相互关系。建筑的构成结构是决定其建筑品质的关键因素。

平面图的多模态特性表现为图像形式（作为…年龄）、图形（作为一组几何实体）以及拓扑（作为图结构）等实体，在建筑设计领域中分别利用不同的数据建模与机器学习框架实现数字化表征与机器理解。其中，平面布局的综合生成，例如平面布局的自动生成[9, 10, 18]或风格迁移[1]，一直是研究的重点。另一条重要的研究主线是建筑构件识别，其目标在于自动从平面布局图像中提取几何特征，如墙体或家具[7, 3, 14]。

尽管用于平面布局的生成模型取得了进展，但鲜有有价值的尝试致力于开发数据驱动的方法来对平面布局进行*reason*，例如通过有效比较数据实例*i.e*来实现平面布局检索。测量相似性方面亦是如此。正如[13]所指出的，平面布局的结构相似性判断是一项具有挑战性的任务——它具有多维度特征，涉及形状与比例、视觉特征以及平面布局各分区之间的关系。广义而言，平面布局的比较旨在识别其底层结构中的共性，因此被称为*structural similarity*。

用于度量楼层平面之间结构相似性的最有效方法，依赖于深度学习得到的向量表示，其目标是使特征向量空间能够反映结构相似性*i.e*。对于结构上相似的楼层平面，其特征向量之间的距离较小；反之亦然。为训练此类模型，文献[8]提出采用弱监督的深度度量学习框架，并通过交并比（IoU）获取相似性标签。为弥补IoU在结构感知方面的不足，文献[13, 4]则采用图匹配网络（GMN）[6]，该方法能够自然地将拓扑信息嵌入到特征向量中。然而，除GMN在实际应用中存在一定的局限性[22]之外，我们认为，若能首先使优化目标与结构相似性更好地对齐，更为简单的框架同样可以学习到同样有效的向量表示。在本研究中，我们提出了一个改进的优化目标，并坚持简洁的设计原则。我们首先系统地考察了现有基于图像和基于图的相似性度量方法的优点与瓶颈。

Intersection-over-Union (IoU)通常被用作一种评估指标，用于衡量结构相似性*e.g*。

用于为深度度量学习模型寻找相似或匹配的样本对[13, 4]，评估结构推理算法的准确性[7]，或评价生成模型的输出多样性[9]。在本文中，我们指出交并比（IoU）无法稳健地衡量结构相似性，原因在于：1）IoU 对平面布局图像表示中的几何扰动过于敏感；2）IoU 往往难以识别空间细分之间（如门、墙、洞口等）的重要连通性差异。

平面布局已成功被建模为图结构[9, 13]，从而使得图匹配算法能够计算一对图之间的距离（相似度）。例如，*Graph Edit Distance* (GED)用于计算将源图转换为另一张与其同构的目标图所需的最小代价[17]。以文献[9]为例，该研究利用GED来检验生成布局的兼容性。尽管GED能够有效刻画拓扑相似性，并在一定程度上克服了IoU的一些局限性，但我们表明，在用于度量结构相似性时，GED本身也存在固有的局限性。

独立来看，基于图像和图的相似性度量均难以全面捕捉平面布局之间的结构相似性。因此，我们并未将图像与图分别处理，而是提出了一种评估指标——SSIG，该指标基于平面布局对应的图像-图对来判定其相似程度。此外，我们还基于SSIG设计了一种高效算法，用于对RPLAN（一个大规模平面布局数据库）按照结构相似性进行排序。我们的主要贡献包括：

- 一项针对大规模平面布局数据库中IoU与GED分布及其相关性的研究，其主要发现为：IoU与GED均无法独立且稳健地表征结构相似性。
- 一种用于衡量楼层平面结构相似性的简单而有效的指标。
- 一种有效的排序技术，用于对大型平面布局数据库进行排序，从而为平面布局检索模型的合理评估与训练提供初始依据。

2. 相关工作

平面图的表示方法。平面图在数字化表示中存在多种形式，每种形式均侧重于不同的关注要素*e.g*：以图像形式呈现，能够刻画诸如材质和家具等细粒度细节[21, 5]；以几何体形式呈现，可显式建模各功能分区的形状、比例及其空间位置[13]；以及以图结构形式呈现，用于建模各功能分区之间的关联关系[9, 13, 18, 12]。

楼层平面分析。针对楼层平面分析的传统方法——或类似的数据，如文档[28]或用户界面——[2]——采用原始启发式方法来近似计算平面布局之间的距离，因此具有实例特定性[11]。近年来，两步法已成为近似计算平面布局相似性的标准方法[27, 16, 20, 23, 21, 19, 25, 12]，其中第一步从图像中提取相关特征（如v7），构建房间连通性的图表示[12]；第二步则基于所提取的特征（如v8）计算距离，并采用子图匹配算法来度量图的相似性[16]。然而，除了两步法容易产生误差传播之外，这类方法还隐含了一个假设，即所提取的特征（如访问图）能够完整且准确地刻画平面布局的所有方面。在本研究中，我们对这一假设提出了质疑，尤其是在涉及平面布局的语义图像表示和访问图表示时。

基于图神经网络的结构相似性。近期，图神经网络（GNN）已被用于表征楼层平面的相似性[13, 8, 4]，并以端到端的方式学习楼层平面的向量表示。其中，文献[4, 13]成功地将图匹配网络（GMN）[6]与基于交并比（IoU）的弱监督标签相结合。由于GMN中存在跨图的信息共享机制，文献[13]发现，GMN能够弥补IoU在结构感知方面的不足，并自然地学习将结构共性嵌入到向量表示中。然而，GMN的一个关键缺陷在于其向量表示无法独立计算，从而限制了实际应用的可行性。我们认为，之所以需要跨图信息共享，根本原因在于所采用的目标函数本质上存在偏差——即试图模仿一种受IoU启发的距离度量。我们证明，我们的度量方法通过融合视觉特征与图结构特征的相似性得分，可用于对楼层平面数据库进行排序，且检索结果与文献[13]中的工作具有相似的特性。

3. 方法

在本节中，我们提出了一种简单而有效的策略，用于数值近似楼层平面之间的结构相似性。形式上，我们寻求两个楼层平面p_1和p_2之间的映射关系 *similarity function* $s\left(\cdot,\cdot\right)$：

$$s\left(p_1, p_2\right) : \mathcal{P} \times \mathcal{P} \rightarrow \mathbb{R}^{+}, \tag{1}$$

其中，$\mathcal{P}$ 为平面布局的（数学）空间；$\mathcal{P}$ 可以是多模态的 *e.g*，即图像与图结构的联合空间：$\mathcal{P} = \mathbb{R}^{H\times W\times 3} \times \mathcal{G}$。目标是使 s 尽可能地逼近平面布局之间的结构相似性：结构相似性越大，s 越大，反之亦然。

该部分分为三个主要部分。第一部分探讨了平面图的建模与归因问题（第3.1节）。第二部分则研究了已知的以及

常用的基于图像和图的相似性度量指标（第3.2节、第3.3节）。第三部分介绍了新的相似性度量指标（第3.4节），并给出了一种能够高效对平面布局数据集进行排序的算法（第3.5节）。

3.1 地面平面图表示

在本研究中，我们考虑了三种广为人知的平面布局表示方法：1）图像表示，2）语义图像表示，以及 3）访问图表示。



图1. 平面布局表示。左：图像视图。中：语义图像。右：访问图。

图像表示 传统上，楼层平面图被建模为图像。所有既为灰度图像或RGB图像，且在像素级别上不包含关于各区域语义的类别信息的楼层平面图，均被称为*pictorial images*、$I \in \mathcal{I} = \mathbb{R}^{H \times W (\times 3)}$（（见图1，左侧）和)。

语义图像中的平面图是由若干子区域（如客厅、浴室等）、开口（如门、窗等）以及分隔构件（如墙体、栏杆等）组成的*structured arrangements*。在我们的定义中，所有为子区域赋予类别标签并以像素级编码语义信息的平面图均被称为*semantic images*，记作 $X \in \mathcal{X} = \{0, 1, \ldots, N_c\}^{H \times W}$，其中$N_c$表示子区域类别的数量（见图1，中心部分）。在语义图像表示中，像素值对应于各子区域类别，例如1代表“客厅”，2代表“浴室”，16代表“内墙”等。

访问图：楼层平面图通常在各功能分区之间存在明确可识别的*relations*，即通过门实现的两个房间之间的访问关系。尽管语义图像能够有效地表征各功能分区的形状与类别，但语义图像地图并未显式地定义各功能分区之间的关系。

相反，楼层平面图可以被赋予一个*access graph*，从而直接揭示各分区的拓扑结构（图1，右）。形式上，图被定义为一个四元组$g = (N, E, \mu, \nu)$，其中N为有限的节点集，E为边集，而μ和ν分别为节点与边的标注函数[15]。在接入图中，节点对应于各个区域，边则表示区域之间的连接。

根据用例和功能的可访问性，节点和边可以具有（一个或多个）属性。通常，房间类型信息编码于节点上，而只有当两间房间之间存在门时才会出现边，因此边本身不携带属性[9, 18, 24]。尽管我们认同通行连通性是房间之间最重要的关系，但仍有另一项重要关系被忽视：房间的邻接关系。房间的邻接关系是影响隐私、结构完整性及功能布局等决策的重要因素*e.g*。因此，在本文后续讨论中，通行图引入了一种连通性类型的属性，其取值为“门”或“相邻”。

由[8]提出，值得注意的是，现有若干方法会利用边特征。具体而言，两个节点之间的边特征是通过成对的几何特征来计算的，例如面积之比或相对位置等。

3.2. 交并比

Intersection-over-Union (IoU) 并不被视为一种严格意义上的距离度量，但在需要衡量区域或集合之间重叠程度的任务中，它是一种被广泛采用的评估指标，例如目标检测或分割任务。相应地，IoU 也常被用作一种度量方法，用于在与平面布局相关的各类应用中评估结构相似性，如用于相似性学习中的相似或匹配平面布局对的查找[13, 4]、分割算法精度的评价[7]，或用于检验平面布局生成结果的多样性[9]。IoU 通常被定义为两个二值图像 X_1 和 X_2 的交集面积与并集面积之比 $\in \{0, 1\}^{H \times W}$:

$$\mathrm{IoU}\left(X_1, X_2\right) = \frac{X_1 \cap X_2}{X_1 \cup X_2}. \tag{2}$$

当图像中存在更多类别时*e.g*，对于语义分割图像（$X_1, X_2 \in \mathcal{X}$），逐类计算交并比（IoU），并将各分类的计算结果进行聚合以得到最终得分。例如，平均交并比（mIoU）即在不同类别上分别计算相对于真实标签的交并比，并取其平均值，从而对每个类别给予同等权重，而不考虑其在图像中所占的比例。

$$\mathrm{mIOU}\left(X_1, X_2\right) = \frac{1}{N_c} \sum_{c=1}^{N_c} \mathrm{IoU}\left(X_1 == c, X_2 == c\right), \tag{3}$$

其中，N_c 表示类别数。

尽管交并比（IoU）是一种强大的度量指标，能够在一定程度上用于近似楼层平面图之间的结构相似性，但其在两个极端情况下往往失效：1）假阴性：低IoU—高结构相似性；2）假阳性：高IoU—低结构相似性。1）IoU对图像中无关的几何扰动过于敏感。

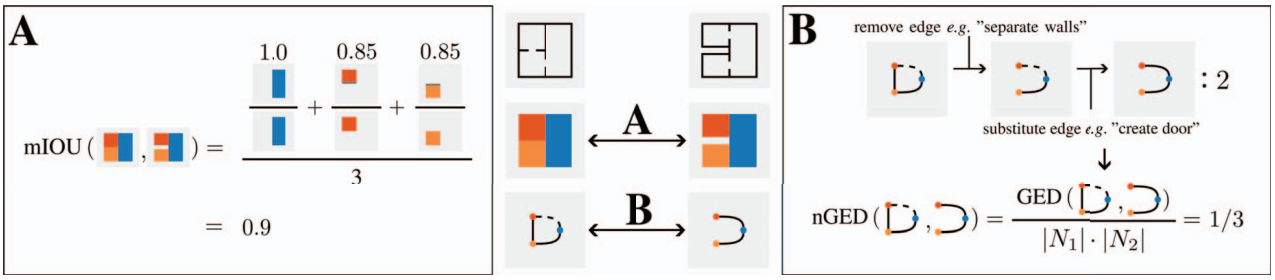


图2. 用于平面布局的视觉与图论相似性度量。A) IoU可直接用作语义图像表示之间相似性的度量指标。语义图像之间的mIoU通过式(3)计算得出（平面布局包含3个语义标签）；在本例中其值为0.90，属于较高水平。B) nGED通过式(5)和式(6)计算：GED等于最短编辑路径，其值为2；两图的阶数均为3，因此nGED为=2/9。当γ =0.4（典型取值）时，1−nGED$(g_1, g_2)^{\gamma}$ ≈0.45。基于视觉的相似性得分（0.90）与基于图论的相似性得分（0.45）存在显著差异，这表明在某些情况下，IoU与GED在“感知”相似性方面呈现负相关关系。

*e.g*平移、旋转和尺度变化。例如，当相同的平面图在图像中位于不同位置时，其交并比（IoU）会较低，从而错误地表明这些平面图在结构上是相似的。2）IoU经常无法正确识别平面图中的连通性。房间之间存在的微小“空隙”几乎无法被 IoU 识别，但这些空隙却能反映结构特征（参见图 2 中的示例）。

3.3 图编辑距离

Graph Edit Distance (GED) [17]是另一种用于度量楼层平面之间相似性的指标，常被应用于生成布局的*e.g*兼容性评估[10]或楼层平面检索[12]。GED是一种通过计算将一个图g_1转化为（与之同构的）图g_2所需的最小代价来量化两者之间相似性（或差异性）的度量，该代价以一系列编辑操作$e_1, e_2, \ldots, e_j$为单位，这些编辑操作被称为*edit path*。典型的编辑操作包括节点和边的删除、插入及替换，且每种操作可赋予不同的代价。给定一组图编辑操作e_i及其相应的代价$c_i(e_i)$，GED（g_1, g_2）的形式化定义为：

$$\mathrm{GED}(g_1, g_2) = \min_{(e_1, e_2, \ldots, e_j) \in \pi(g_1, g_2)} \sum_{j=1}^{k} c_j(e_j), \quad (4)$$

其中，$\pi(g_1, g_2)$ 表示将 g_1 转换为（与之图同构的）g_2 的所有编辑路径集合。在本研究中，所有编辑操作的代价均相同，因此式（4）可简化为：

$$\mathrm{GED}(g_1, g_2) = \min_{k} (e_1, e_2, \ldots, e_k), \quad (5)$$

使得 $(e_1, e_2, \ldots, e_k) \in \pi(g_1, g_2)$。在本例中，GED 等价于所需的最小编辑操作次数。为了将 GED 归一化至 0 到 1 之间，我们通过将 GED 除以……来定义 *Normal- ized Graph Edit Distance* (nGED)。

图$|N_1|$和图$|N_2|$的阶（即节点数）之积：

$$\mathrm{nGED}(g_1, g_2) = \frac{\mathrm{GED}(g_1, g_2)}{|N_1| \cdot |N_2|}. \quad (6)$$

nGED可用作度量两个楼层平面拓扑结构之间相似程度的指标；其中，较小的nGED值表明这两个楼层平面具有相似的拓扑特征，这可能反映出两栋建筑在人流或功能布局方面存在共性。

nGED 存在若干局限性。首先，对于给定的接入图而言，可能存在的不同平面布局数量极其庞大，其中许多对应的平面布局对在结构上并不相似（见图 3）。其次，尚不清楚哪些编辑代价能够准确反映结构相似性：移除一个节点或一条边的代价更高？节点标签是否具有重要性？等等。第三，nGED 的计算开销极大，这限制了其在实时系统中的应用*e.g*以及在搜索引擎中的平面布局检索。我们在第 4.2 节中将进一步详述这些不足之处。

在第4.3节中，我们基于RPLAN [26]数据集，对nGED与mIoU之间的趋势及相关性进行了实证研究。

3.4. 一种基于视觉引导的图编辑距离

独立来看，IoU 和 GED 均无法全面地刻画平面布局之间的结构相似性。因此，我们不将图像与图分别处理，而是提出一种基于语义图像访问图来度量其接近程度的指标。我们将一对平面布局（p_1, p_2）之间的相似性定义为：

[1]Note that Eq. 6 does not strictly normalizes GED. Even so, for floor plans *e.g*., in [26], nGED will always be below 1. Furthermore, the product of the orders, instead of for example the sum, nicely spreads the nGED distributions.

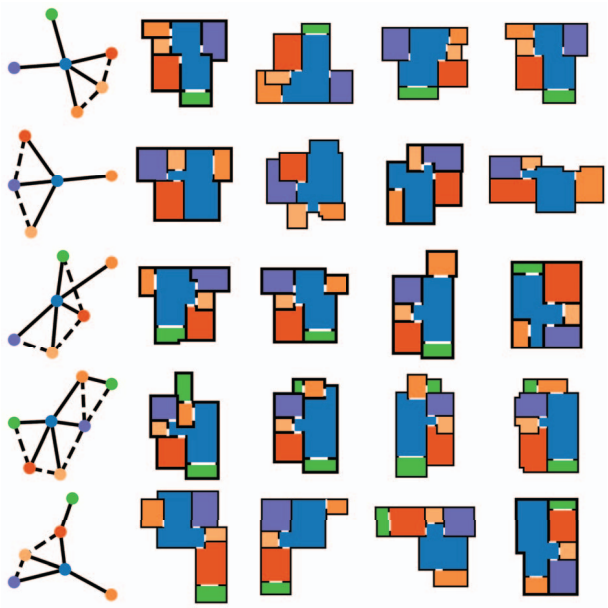


图3. 图到图像示例。每一行分别展示一个访问图（第1列）以及若干随机选取的对应楼层平面语义图像（第2至5列）。

$$\mathrm{SSIG}\left(p_1, p_2\right) = \frac{\mathrm{mIoU}\left(X_1, X_2\right) + \left(1 - \mathrm{nGED}\left(g_1, g_2\right)^{\gamma}\right)}{2}. \tag{7}$$

该方法被称为SSIG（基于IoU与GED的结构相似性），其本质是计算基于IoU的相似性度量与基于归一化广义编辑距离（nGED）的相似性度量之间的加权平均。其中，$\gamma \in \mathbb{R}^{+}$是一个权重参数，用于调节nGED相对于mIoU的重要性：γ越大，则nGED的影响力越强，反之亦然。[2]例如，在RPLAN[26]中，当γ =为0.4时，mIoU与nGED的分布趋于平衡。具体而言，此处的“分布平衡”是指IoU与nGED的概率密度函数具有尽可能大的重叠程度。

3.5. 用于排序的高效算法

即使对于小型图，GED也是一项计算密集型度量，通常每对楼层平面布局的计算需要数秒。当在大型数据集上使用SSIG进行评估、成对样本挖掘或直接的楼层平面布局检索时，时间约束极大地限制了其实际应用。为此，我们提出了一种能够显著加速检索过程并快速发现结构相似配对的算法。

首先，对数据集中每一对平面布局组合分别计算mIoU。其次，对于每个平面布局类别，仅保留mIoU得分位于50至100之间的最佳组合集合。第三，对每组重新剩余的配对。第四，针对每个楼层平面标识，相应的列表按SSIG值进行降序排序。

该算法假定最佳匹配（SSIG得分最高）位于n个最优的mIoU对中。在下一节中，我们通过实验发现，当n足够大时，这一假设通常成立。在第4.4节中，我们进一步表明，对于RPLAN排序而言，该假设在相对较小的n条件下亦成立。对于规模为N（通常介于1万至10万之间）的数据集，该算法的运行速度比穷举法快几个数量级。

对排序算法及其与楼层平面检索系统之间关系的评估将在下一节（第4节）中予以阐述。

4. 结果与评估

4.1 数据

在本文中，我们采用RPLAN[26]进行分析与评估。RPLAN是一个大规模数据集，包含带有语义分割区域的平面布局图像，涵盖亚洲地区的8万套单户型公寓（v15）。我们进一步对数据集进行了清洗，剔除了若干房间之间在拓扑结构上互不连通、且无任何门洞的公寓（v16）。此外，我们还移除了那些未完全连通，或者我们的图提取算法无法可靠地构建其访问图的公寓。经清洗后的数据集包含5.6万套公寓（v17）。进一步地，我们发现RPLAN中存在大量（近似）重复样本。为评估排序算法（第4.4节），我们按mIoU阈值0.87（v18–v19）剔除这些（近似）重复样本，以减少结果中的冗余。在分析mIoU与nGED的分布及相关性时，我们也同样剔除了重复样本（v20）。

4.2. 分布

为了理解成对相似性度量（mIoU 和 nGED）之间的关系及其与结构相似性的关联，我们首先考察这些成对相似性度量的概率密度函数（分别为 p_{IoU} 和 p_{GED}）。p_{IoU} 和 p_{GED} 通过计算超过一百万对随机采样的平面布局的 IoU 和 GED 来近似得到。为简便起见，我们用“IoU”和“GED”代替“mIoU”和“nGED”。

IoU 按照式（3）进行计算，且计算范围涵盖除“背景”之外的所有细分类别。其分布直方图如图4中左侧中间的蓝色曲线所示。该分布的均值约为0.25，这意味着平均约有25%的像素存在重叠。我们还绘制了按每张平面图标识计算的、IoU得分排名前50的样本的IoU分布，以橙色表示。正如预期的那样，与

[2]Note that nGED $\in (0, 1)$, hence increasing the power term decreases nGED.

在完整的交并比（IoU）分布中，均值发生了显著偏移。在1.0附近出现的峰值可归因于数据集中存在的大量（近似）重复样本。

为展示平面布局样本的多样性，图4（顶行）展示了具有不同“原创性”得分的平面布局。原创性通过某一给定样本与其余所有样本之间的平均交并比（IoU）得分来计算：越靠右（≈ 0.1），原创性越高*i.e*，出现频率越低；越靠左（≈ 0.4），原创性越低*i.e*，出现频率越高。总体而言，原创性主要与房间及边界形状的复杂程度呈正相关。

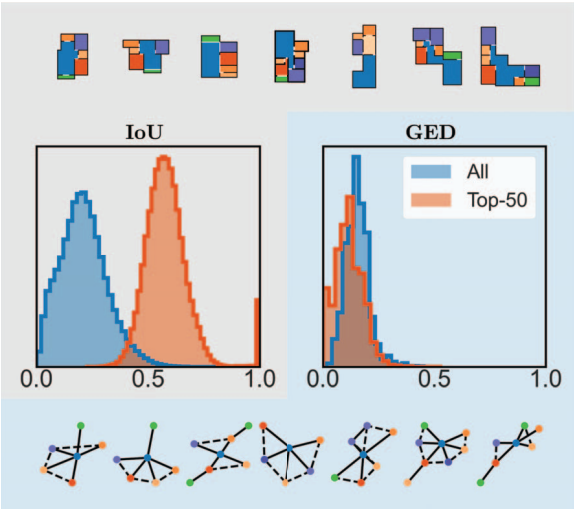


图4. IoU与GED的分布及原创性。居中的两幅图分别展示了IoU（左）与GED（右）的分布：蓝色表示所有样本的分布，橙色仅考虑前50名*on IoU*。顶部给出了基于平均IoU的语义图像原创性指标，底部则给出了基于基础图出现频率的图原创性指标；从左至右，原创性逐渐增强。

GED 和 nGED 按照式（5）和式（6）计算，因此节点与边的删除、插入及替换代价均保持一致。完整分布的直方图如图4中右上角的蓝色曲线所示。我们还绘制了按每个平面布局标识选取的得分前50个样本集*on IoU*的GED分布，以橙色表示。令人惊讶的是，完整分布与前50样本分布几乎相似，这表明IoU与GED之间几乎不存在相关性（即便存在也十分微弱）。这种较弱的相关性将在下一节中进一步探讨。

值得注意的是，在我们的随机配对样本中，仅有50个独特的GED值。GED值的取值范围较为有限，这可归因于：

首先，共享相同底层*base graph*的平面图对的数量——即数据集中所有可能的图中，每一对组合均彼此同构：

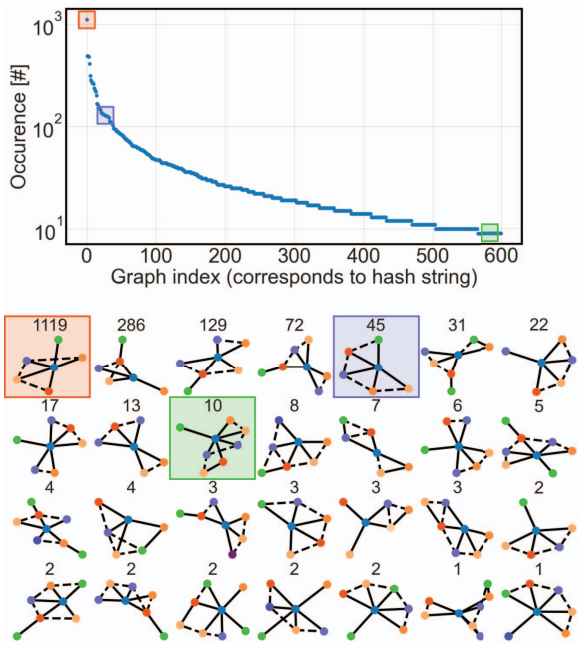


图5. 基础图的分布。上方的图表展示了至少出现9次的基础图的分布情况（按出现次数降序排列）。下方则针对若干随机选取的平面布局绘制了基础图。对于部分基础图，我们通过彩色方框标示其在分布中的位置。

g_1 与 g_2 同构——规模相对较大。为阐明这一观点，我们按对应楼面平面图的数量对所有基础图进行排序，并展示了基础图出现频次之间的显著不均衡（见图5）。例如，超过25%的数据（≈1.4万样本）仅对应于排名前100的基础图。如图4（底部一行）所示，与IoU原创性评分类似，我们也基于图的原创性对楼面平面图进行评分。图的原创性以给定基础图所对应的楼面平面图数量为依据：原创性越高，每个基础图对应的楼面平面图数量越少。尽管图的原创性模式有待进一步深入研究，但平均而言，随着原创性的提高，节点数和边数均略有增加。

其次，从图的原创性分布所揭示的实证结果来看，仅就拓扑结构（即图的结构）而言，其分布范围较小，这是因为这些图在规模（连接数量）和阶数（子划分数量）上均受到限制。此外，拓扑特征也较为有限。通常，接入图呈现出类似“花状”的结构，因而以单个节点为中心。该中心节点通常是客厅和/或走廊。

事实上，大多数平面布局均源自有限的一组基础图，且仅考虑少数节点和边的属性，这导致仅基于图相似性来度量结构相似性的方法效果不佳。

4.3. 相关性

我们进一步研究了IoU与GED之间的相关性。图6展示了IoU与GED的二维密度分布，并以热图形式呈现。当视觉相似度*i.e.*、*higher*的IoU值增加时，基于图的相似度*i.e.*、*lower*的GED值也随之增加，我们将其定义为正相关。实质上，我们是在量化IoU与*negative*GED之间的相关性。热图显示，随着IoU取值范围的增大，GED的分布逐渐向较低值方向偏移，因此IoU与GED呈正相关。具体而言，mIoU与−nGED之间的皮尔逊相关系数为0.503，表明GED与IoU存在中等程度的相关性。然而，不同IoU区间对应的GED分布之间往往存在较大的重叠区域。特别地，在38%的情况下，IoU与GED呈现出相反的变化趋势——此处的“相反”是指较高的IoU对应较高的GED，或较低的IoU对应较低的GED。图7中列举了若干IoU与GED呈现相反变化的具体实例。

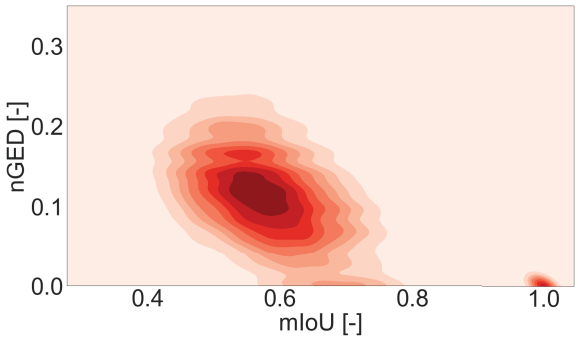


图6. IoU与GED的二维密度分布热图。结果显示，IoU与-GED之间存在中等程度的相关性（0.503）。然而，数据分布较为分散，表明IoU与GED在预测彼此时往往缺乏较高的置信度。

从图7所示的三元组中，IoU与GED的诸多特性得以显现。对于一个锚框，我们定义pos@IoU为正样本（IoU较高），neg@IoU为负样本（IoU较低）；同样地，pos@GED指GED较低的正样本，neg@GED指GED较高的负样本。最为显著的是，IoU对建筑物整体轮廓的敏感性：在所有情形下，锚框与pos@IoU之间的整体轮廓几乎完全一致，而与pos@GED则存在细微差异。另一方面，锚框与pos@IoU之间的房间数量往往不同，但与pos@GED之间的房间数量却几乎总是相等：增减房间会显著增大GED，但在许多情况下对IoU的影响并不明显。pos@IoU与pos@GED之间的另一区别在于，房间形状的变化——尤其是对中心空间的调整——会被GED所惩罚，却对IoU产生不利影响。这些实例揭示了度量建筑平面结构相似性的难度。显然，这两种度量指标各自独立地能够—

not fully grasp structural similarity.



图7. 在RPLAN数据集上，IoU与GED之间的负例示意图。IoU对房间的尺度和形状较为敏感，而GED则能够捕捉房间之间的连接关系。

4.4. 平面图检索

我们评估了第3.5节中提出的排序算法，并从定性角度将其检索结果与基于IoU和GED的独立排序方法，以及基于深度学习度量的学习型检索方法[13]进行了比较。

我们首先确定n的合理取值——即在按IoU排序后用于进一步SSIG评估的样本数量。图9展示了针对不同n取值时，IoU、GED和SSIG的分布情况。根据我们的观察，当SSIG取值相对较大（$>\geqslant 0.7$）时，每次线性增加n所新增的样本数量逐渐减少。对于RPLAN而言，我们发现n >==50时，SSIG排名前10的样本几乎不会发生变化。与在整个数据集上计算SSIG相比，此时只需计算50次即可。我们认为，在RPLAN的情形下，至少就粗粒度的结构相似性匹配而言，IoU是恰当的初始步骤；而GED则有助于在更精细的层次上度量结构相似性。因此，我们将所提出的排序方法称为“视觉引导的图编辑距离”。

与GMN相比，我们的算法在计算效率上更具优势。根据平面布局所对应的访问图的规模及其独特性，对于每个未见过的样本，我们的算法在单个CPU上完成其完整排序所需的时间介于1至5秒之间。相比之下，LayoutGMN完成相同计算则需约1500秒。因此，与GMN相比，我们的算法在计算效率上更具优势。

我们方法的随机抽取检索结果（前10条）为



图8. 本方法的检索结果。最左侧为查询图像，右侧为检索结果。红色和蓝色的半透明框分别表示IoU排名和GED排名。

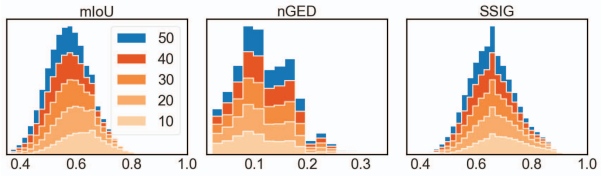


图9 不同v0下的IoU、GED和SSIG分布。不同颜色代表不同的v1。尤其值得注意的是，随着v2的增大，IoU和SSIG的均值均显著下降。

如图8所示，并与仅基于IoU和仅基于GED的排序进行了对比。红色和蓝色分别表示IoU和GED的排序结果。不出所料，SSIG、IoU和GED的排序结果存在显著差异，这可归因于IoU与GED之间的相关性仅为弱正相关（参见第4.3节）。与仅基于IoU或仅基于GED的检索结果相比，可以看出SSIG确实能够弥补IoU和GED在某些情况下的不足。例如，在图8的最后一行中，前4个检索结果尽管IoU值较低，但通过GED得到了补偿；而第5个检索结果尽管GED值较低，却通过IoU得到了补偿。类似的补偿机制同样存在于深度学习度量的检索结果中，详见文献[13, 4, 8]。

5. 结论与未来工作

在本研究中，我们表明，仅依靠基于图像或基于图的相似性度量，可能不足以稳健地衡量楼层平面图之间的结构相似性。为此，我们将交并比（IoU）与图编辑距离（GED）相结合，构建了一种名为SSIG的综合度量指标，从而克服了上述不足。定性分析结果表明，按照SSIG排序的楼层平面图数据库，在特征上与现有最先进方法的输出结果具有较高的相似性。

使用广义匹配网络（GMNs）进行排序计算。

然而，本研究仅限于对IoU和GED的考察，并未考虑其他广为人知的基于图像与图的相似性度量。此外，我们尚未开展任何用户研究以进一步严格验证我们的结论。在后续研究中，我们期望能够同时解决上述两项局限性。

如式1所定义的相似性度量采用了一种与任务无关的设定方式——该度量将平面布局的相似性视为一个整体性的指标。然而，在许多情况下，更为现实的相似性建模方式可能是动态的（例如，基于类别），从而在多种应用场景下允许不同的相似性评分，如用于定制化的平面布局搜索引擎、平面布局生成的评估等。我们的目标是在未来进一步研究此类建模方法。

我们相信，SSIG将为基于数据的平面布局研究开辟新途径，例如为深度度量学习框架提供更为自然的优化目标，而这些框架并不一定需要在不同分支之间进行信息共享。

参考文献

[1] 斯塔尼斯拉夫·沙尤。AI + 架构 |：迈向一种新方法。*Harvard University*，2019年1月。1 [2] 比普拉布·德卡、黄子峰、查德·弗兰岑、乔舒亚·希布施曼、丹尼尔·阿费尔甘、李阳、杰弗里·尼科尔斯和兰吉塔·库马尔。Rico：一个用于构建数据驱动型设计应用的移动应用数据集。载于*Proceedings of the 30th Annual ACM Symposium on User Interface Software and Technology*，UIST ’17，第845–854页，美国纽约州纽约市，2017年10月。美国计算机协会。2 [3] 什雷亚斯·汉帕利、西尼萨·斯特科维奇、萨扬·德布·萨卡尔、切坦·S·库马尔、弗里德里希·弗劳恩多尔费尔和文森特·勒佩蒂。面向三维场景理解的蒙特卡洛场景搜索。

在*2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*中，第13799–13808页，美国田纳西州纳什维尔，2021年6月。IEEE。1 [4] 金炯超、薛舟和冷彪。SHRAG：用于楼层平面表示的语义层次图。载于*2022 International Conference on 3D Vision (3DV)*，第271–279页，2022年9月。ISSN：2475-7888。1, 2, 3, 8 [5] 拉西卡·卡德、克鲁帕·贾里瓦拉、奇兰乔伊·查托帕迪亚耶和乌马帕达·帕尔。一种适用于多方向楼层平面图像检索的旋转与尺度不变方法。*Pattern Recog- nition Letters*，145:1–7，2021年5月。2 [6] 李宇佳、顾晨杰、托马斯·杜利恩、奥里奥尔·维尼亚尔斯和普什米特·科利。用于学习图结构对象相似性的图匹配网络。载于*Proceedings of the 36th International Conference on Machine Learning*，第3835–3845页。PMLR，2019年5月。ISSN：2640-3498。1, 2 [7] 刘晨、吴嘉俊、普什米特·科利和古川康隆。光栅到矢量：重新审视楼层平面转换。载于*2017 Proceedings of the IEEE International Conference on Computer Vision*，第2195–2203页，2017年。1, 2, 3 [8] 迪普·马南达尔、丹·鲁塔和约翰·科洛莫斯。利用图网络学习用户界面布局的结构相似性。载于安德烈亚·韦达尔迪、霍斯特·比绍夫、托马斯·布罗克斯和扬-迈克尔·弗拉姆主编的*Computer Vision – ECCV 2020*，第12367卷，第730–746页。施普林格国际出版公司，瑞士尚贝里，2020年。系列名称：计算机科学讲义。1, 2, 3, 8 [9] 纳尔逊·瑙阿塔、张凯鸿、郑钦毅、格雷格·莫里和古川康隆。House-GAN：用于图约束房屋布局生成的关联式生成对抗网络。载于安德烈亚·韦达尔迪、霍斯特·比绍夫、托马斯·布罗克斯和扬-迈克尔·弗拉姆主编的*Computer Vision – ECCV 2020*，计算机科学讲义，第162–177页，瑞士尚贝里，2020年。施普林格国际出版公司。1, 2, 3 [10] 纳尔逊·瑙阿塔、塞皮德萨达特·侯赛尼、张凯鸿、胡昂、郑钦毅和古川康隆。House-GAN++：面向专业建筑师的智能计算代理之生成对抗布局优化网络。第13632–13641页，2021年。1, 4 [11] 劳伦斯·奥戈尔曼和朗加查尔·卡斯图里。*Executive briefing: document image analysis*。IEEE计算机学会出版社，美国加利福尼亚州洛斯阿拉米托斯，1997年。2 [12] 朴慧珍、徐惠教、金在日和秋承妍。基于空间关系数据集的图神经网络楼层平面推荐系统。*Journal of Building Engineering*，第106378页，2023年3月。2, 4 [13] 阿克谢·加迪·帕蒂尔、李曼怡、马修·费舍尔、马诺利斯·萨瓦和张浩。LayoutGMN：用于结构布局相似性分析的神经图匹配。载于*2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*，第11043–11052页，美国田纳西州纳什维尔，2021年6月。IEEE。1, 2, 3, 7, 8 [14] 莫尔特扎·拉赫巴尔、穆罕默德贾瓦德·马赫达维内贾德、阿米尔·H. D. 马尔卡齐和穆罕默德雷扎·贝马尼安。通过深度学习与基于智能体的方法进行建筑布局设计建模：一种混合方法。*Journal of Building Engi- neering*, 47:103822, 2022年4月。1 [15] Pau Riba、Andreas Fischer、Josep Lladós 和 Alicia Fornés。基于图神经网络学习图编辑距离。*Pat- tern Recognition*, 120:108132, 2021年12月。3 [16] Qamer Uddin Sabri、Johannes Bayer、Viktor Ayzenshtadt、Syed Saqib Bukhari、Klaus-Dieter Althoff 和 Andreas Dengel。基于语义模式的建筑平面图检索：结合案例推理与基于图的搜索技术及其评估与可视化。载于 *Proceedings of the 6th International Conference on Pattern Recognition Applications and Methods*，第50–60页，葡萄牙波尔图，2017年。SCITEPRESS——科学技术出版公司。2 [17] Alberto Sanfeliu 和 King-Sun Fu。用于模式识别的带属性关系图之间的距离度量。*IEEE Transactions on Systems, Man, and Cybernetics*, SMC-13(3):353–362, 1983年5月。会议名称：IEEE系统、人机与控制论汇刊。2, 4 [18] Mohammad Amin Shabani、Sepidehsadat Hosseini 和 Ya- sutaka Furukawa。HouseDiffusion：基于离散与连续去噪扩散模型的矢量化建筑平面图生成，2022年11月。arXiv:2211.13287 [cs]。1, 2, 3 [19] Divya Sharma 和 Chiranjoy Chattopadhyay。面向细粒度建筑平面图检索的高层特征聚合。*IET Computer Vision*, 12(5):702–709, 2018年。电子版：https://onlinelibrary.wiley.com/doi/pdf/10.1049/iet-cvi.2017.0581。2 [20] Divya Sharma、Chiranjoy Chattopadhyay 和 Gaurav Harit。建筑平面图语义匹配的统一框架。载于*2016 23rd International Conference on Pattern Recognition (ICPR)*，第2422–2427页，2016年12月。2 [21] Divya Sharma、Nitin Gupta、Chiranjoy Chattopadhyay 和 Sameep Mehta。DANIEL：用于建筑平面图自动分析与检索的深度架构。载于*2017 14th IAPR International Conference on Document Analysis and Recognition (ICDAR)*，第01卷，第420–425页，2017年11月。ISSN：2379-2140。2 [22] Chia-Ying Shih 和 Chi-Han Peng。基于相似性距离的建筑平面图探索框架，2022年11月。arXiv:2211.07331 [cs]。1 [23] Yuki Takada、Naoto Inoue、Toshihiko Yamasaki 和 Kiy- oharu Aizawa。融合布局类型分类与房间存在预测的多任务学习的相似平面图检索。载于*2018 IEEE International Conference on Consumer Electronics (ICCE)*，第1–6页，2018年1月。ISSN：2158-4001。2 [24] Hao Tang、Zhenyu Zhang、Humphrey Shi、Bo Li、Ling Shao、Nicu Sebe、Radu Timofte 和 Luc Van Gool。用于图约束下住宅生成的图Transformer GAN，2023年3月。arXiv:2303.08225 [cs]。3 [25] Markus Weber、Christoph Langenhan、Thomas Roth- Berghofer、Marcus Liwicki、Andreas Dengel 和 Frank Pet- zold。a.SCatch：用于建筑平面图检索的语义结构。载于 Isabelle Bichindaritz 和 Stefania Mon- tani 主编的 *Case-Based Reasoning. Research and Develop- ment*，《计算机科学讲义》，第510–524页，柏林—海德堡，2010年。Springer出版社。2

[26] 吴文明、傅晓明、唐睿、王宇涵、齐宇豪和刘利刚。基于数据驱动的住宅建筑室内平面生成。
ACM Transactions on Graphics，38(6):234:1–234:12，2019年11月。2, 4, 5 [27] 山田满太郎、王雪婷和山崎俊彦。从平面图图像中提取图结构及其在相似房产检索中的应用。载于
2021 IEEE
International Conference on Consumer Electronics (ICCE)，第1–5页，2021年1月。ISSN：2158-4001。2 [28] 钟旭、唐建斌和安东尼奥·希梅诺·耶佩斯。Pub-LayNet：有史以来最大的文档版面分析数据集，2019年8月。arXiv:1908.07836 [cs]。2